Principinių komponenčių analizė (PCA)

Algoritmo pristatymas

R. Černiauskaitė, E. Dudutytė, K. Kemeža

2026 m. kovo 5 d.

1. Įvadas
2. PCA algoritmas
3. PCA modifikacijos
4. Rezultatų interpretacija
5. Privalumai ir trūkumai
6. Išvados

1 Įvadas

2 PCA algoritmas

3 PCA modifikacijos

4 Rezultatų interpretacija

5 Privalumai ir trūkumai

6 Išvados

Kas yra PCA?

Pagrindinių komponenčių analizė (*Principal Component Analysis*, PCA) — tai metodas, skirtas supaprastinti didelius duomenų rinkinius mažinant jų dimensijų skaičių. Procesas vykdomas sukuriant naujus, tarpusavyje tiesiškai nepriklausomus kintamuosius, kurie išlaiko maksimalią duomenų sklaidą, užtikrinant minimalų informacijos praradimą.

1 Įvadas

2 PCA algoritmas

3 PCA modifikacijos

4 Rezultatų interpretacija

5 Privalumai ir trūkumai

6 Išvados

Algoritmo veikimo principai

Pagrindiniai PCA etapai:

1. Standartizuojami duomenys;
2. Skaičiuojama koreliacijos matrica;
3. Nustatomos tikrinės reikšmės ir vektoriai;
4. Atrenkamos komponentės;
5. Projektuojami duomenys.

Notacija

Tarkime, turime p vektorių $x_1, x_2, \ldots, x_p$, kurie yra n-os dimensijos arba $n \times p$ duomenų matricą X. Tada siekiame kiekvieno matricos X stulpelio tiesinės kombinacijos su didžiausia variacija.
Tokia tiesinė kombinacija išreiškiama taip

$$\sum_{i=1}^{p} a_i \mathrm{x}_i = \mathrm{Xa},$$

kur a yra konstantų $a_1, a_2, \ldots, a_p$ vektorius.

Standartizavimas

Kadangi pradinių duomenų skalės ir matavimo vienetai dažniausiai skiriasi, siekiant suvienodinti kintamųjų svorius, atliekamas duomenų standartizavimas, kad kiekvienas požymis turėtų nulinį vidurkį ir vienetinę dispersiją.

$$Z = \frac{X - \mu}{\sigma},$$

Čia μ yra nepriklausomų požymių vidurkių vektorius $\mu = \{\mu_1, \ldots, \mu_p\}$, o σ - požymių vektorių standartinis nuokrypis $\sigma = \{\sigma_1, \ldots, \sigma_p\}$.

Kovariacijų matrica, tikrinės reikšmės ir vektoriai

Tarkime, kad X jau normalizuotas. Tada kovariacijų matrica tampa tapati koreliacijų matricai. Toliau apskaičiuojama $p \times p$ dydžio koreliacijų matrica S ir ieškoma projekcijos, t. y. tokios tiesinės kombinacijos $Xa = \sum_{j=1}^{p} a_j x_j$, kurios dispersija būtų didžiausia.
Ši dispersija išreiškiama kvadratine forma $a^T Sa$, kur a vektorius yra apribojamas sąlyga $a^T a = 1$.
Siekiama rasti vektorių a, kuris maksimizuotų dispersiją, pasinaudojant Lagranžo funkcija

$$L(a, \lambda) = a^T Sa - \lambda(a^T a - 1) \tag{1}$$

Kovariacijų matrica, tikrinės reikšmės ir vektoriai

(1) išraišką diferencijuojant vektoriaus a atžvilgiu ir prilyginant nuliui, gauname

$$Sa = \lambda a$$

Taigi, ieškomas koeficientų vektorius a - kovariacijų matricos tikrinis vektorius, o jį atitinkantis Lagranžo daugiklis λ yra tikrinė reikšmė. Kadangi projekcijos dispersija yra tiesiogiai lygi tikrinei reikšmei:

$$var(Xa) = a^T Sa = a^T \lambda a = \lambda$$

Siekdami maksimizuoti dispersiją, renkamės didžiausią tikrinę reikšmę λ_1 ir ją atitinkantį tikrinį vektorių a_1. Tai yra pirmoji pagrindinė komponentė.

Kovariacijų matrica, tikrinės reikšmės ir vektoriai

Analogiškai randamos ir kitos komponentės $a_2, a_3, \ldots, a_p$, tenkinančios ortogonalumo sąlygą ($a_i^T a_j = 0$). Jos išrikiuojamos mažėjimo tvarka pagal jų paaiškinamą dispersiją:
$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$.
Kiekviena sekanti komponentė paaiškina vis mažesnę duomenų sklaidos dalį.

SVD

Singuliarinių reikšmių dekompozicija (angl. *Singular Value Decomposition*, SVD) - tai tiesinės algebros metodas leidžiantis bet kokią stačiakampę matricą X išskaidyti į trijų matricų sandaugą

$$X = U\Sigma V^T, \tag{2}$$

kur U ir V yra ortogonalios matricos $n \times n$ ir $p \times p$ atitinkamai, o Σ yra $n \times p$ diagonali matrica.
SVD yra modernus ir skaičiavimo atžvilgiu stabilus būdas rasti pagrindines komponentes nenaudojant tiesioginio kovariacijos matricos skaičiavimo.

SVD ryšys su PCA

Jei paimsime (2) išraišką, tai

$$X^T X = V\Sigma^T U^T U\Sigma V^T = V\Sigma^T \Sigma V^T = VDV^T,$$

kur $D = \Sigma^T \Sigma$ yra diagonali su singuliarių reikšmių kvadratais. Tuomet padauginus abejas puses iš V gauname

$$(X^T X)V = VD.$$

Čia V stulpeliai yra principinės komponentės, D pagrindinėje įstrižainėje yra tikrinės reikšmės (variacijos) $\lambda_1, \lambda_2, \ldots, \lambda_p$.

SVD ryšys su PCA

Taip pat $X^T X = (n-1)S$ iš imties kovariacijos apibrėžimo tarp j-jo ir k-jo stulpelių kai duomenys jau centruoti, t. y.

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^{n} x_{ij} x_{ik},$$

o matriciniu pavidalu $\frac{1}{n-1} X^T X$ gaunamos dispersijos ir kovariacijos tarp visų požymių.
Taigi naudojant SVD metodą, gaunami tie patys rezultatai, tačiau pranašesniu būdu skaičiavimų resursų atžvilgiu.

Pagrindinės komponentės ir projekcija

Tikriniai vektoriai nurodo naujų ašių kryptį ir yra principinės komponentės, o tikrinės reikšmės nusako komponentė svarbą. Kiek sklaidos paaiškina i-oji pagrindinė komponentė apskaičiuojama pagal santykį

$$\frac{\lambda_i}{\sum_{j=1}^{p} \lambda_j}.$$

Pagrindinių komponenčių yra tiek kiek yra požymių ir renkamės tiek pirmųjų, kad jos paaiškintų norimą dalį sklaidos. Parinkus pagrindines komponentes sukuriama projekcija Y ant naujų ašių padauginus pradinių duomenų matricą X iš atrinktų, pirmųjų k tikrinių vektorių matricos A_k, t. y. $Y = XA_k$.

3D pavyzdys

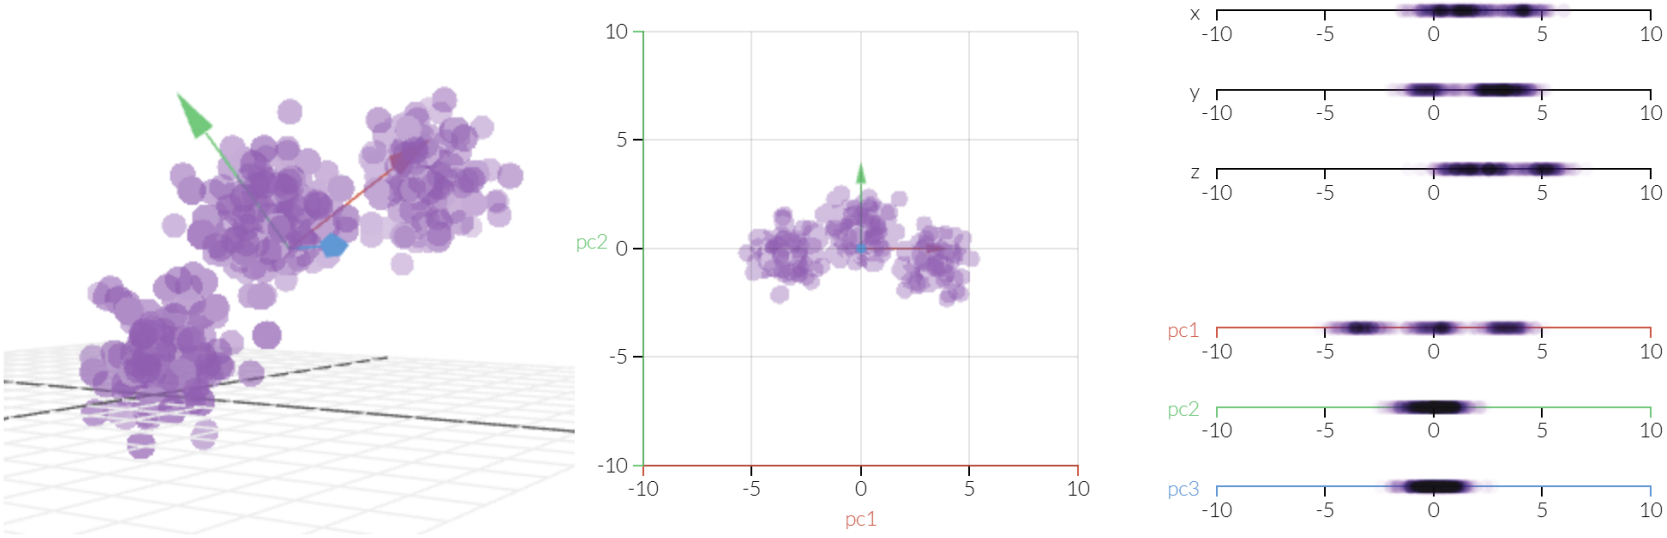

pav. 1: 3 dimensijų pavyzdys [1]

1 Įvadas

2 PCA algoritmas

3 PCA modifikacijos

4 Rezultatų interpretacija

5 Privalumai ir trūkumai

6 Išvados

PCA algoritmo modifikacijas

1. Kernel PCA (KPCA);
2. Sparse PCA (SPCA);
3. Robust PCA (RPCA);
4. Incremental PCA (IPCA);
5. Probabilistic PCA (PPCA);
6. Functional PCA (FPCA);
7. Randomized PCA (RPCA);
8. Generalized PCA (GPCA);
9. Sparse Principal Component Techniqe (SCoTLASS);
10. Local/Manifold PCA;
11. Uncentered PCA;
12. Dual PCA.

Branduolių PCA

Branduolių PCA (angl. *Kernel PCA*, KPCA) - tai netiesinis dimensijos mažinimo metodas. Tiesiškai neatskiriamų taškų aibė transformuojama sukuriant aukštesnės dimensijos projekciją naudojant netiesinę funkciją $\Phi : \mathbb{R}^n \to \mathbb{R}^m, m > n$. Tačiau vietoj brangios transformavimo operacijos ir tuomet skaliarinių sandaugų matricos $K = \phi(X)\phi(X^T)$ skaičiavimo naudojamas vadinamas *Kernel Trick*, t. y. K skaičiuojama iškart parinkus branduolio funkciją $k(x_i, x_j)$ (pvz. Gauso), kur x_i yra taško koordinatės. K apima visus porinius skaliarinių sandaugų įvertinimus. Toliau branduolio matrica centruojama:
$\tilde{K} = K - \frac{2}{d}(1_{d\times d})K - (\frac{1}{d}1_{d\times d})K(\frac{1}{d}1_{d\times d})$, kur d - mokymo aibės dydis. Galiausiai sprendžiamas tikrinių reikšmių ir tikrinių vektorių uždavinys $\tilde{K}\alpha_i = \lambda_i\alpha_i$ ir sukuriama x taško projekcija ant j-osios naujos ašies: $y_j = \sum_{i=1}^{d} \alpha_{ij} k(x_i, x), j = 1, 2, \ldots, m$, m - dimensijų skaičius.

Retoji PCA

Retoji PCA (angl. *Sparse PCA*, SPCA) atrenka svarbiausius kintamuosius. Tikslas pagrindinėse komponentėse palikti tik svarbiausių požymių įtaką, o kitų požymių svoriai nustatomi į nulį. Tai pasiekiama per įvedama baudos funkciją (dažniausiai *L1* arba *Lasso* reguliavimą). Todėl rezultatai tampa lengviau interpretuojami.

Prižiūrima PCA

Prižiūrimas PCA (angl. *Supervised PCA*) - tai PCA apibendrinimas, skirtas dimensijų mažinimui klasifikavimo ir regresijos uždaviniuose. Nors egzistuoja įvairūs būdai įtraukti papildomą informaciją apie atsaką, literatūroje siūlomas Hilbert-Schmidt nepriklausomybės kriterijus (HSIC), kuris leidžia analitiškai apskaičiuoti duomenų projekciją, maksimizuojančią statistinį ryšį tarp požymių ir atsako kintamojo. Tai užtikrina, kad sumažinus dimensijų skaičių, išliktų tik ta informacija, kuri yra tiesiogiai naudinga klasifikavimo ar regresijos tikslumui.

Atsparioji PCA

Atsparioji PCA (angl. *Robust*, RPAC) yra skirta susidoroti su duomenų didelėmis išskirtimis. Šis metodas pradinę matricą išskaido į dvi dalis: žemo rango (pagrindinė struktūra) ir retąją matricą (klaidos ar išskirtys). Šis algoritmas ignoruoja didelius nuokrypius duomenyse, todėl yra tiksliai atpažįstama esminė informacija net ir stipriai sugadintuose duomenyse.

1 Įvadas

2 PCA algoritmas

3 PCA modifikacijos

4 Rezultatų interpretacija

5 Privalumai ir trūkumai

6 Išvados

Tikrinės reikšmės

Nuolydžio (angl. *Scree*) diagrama rodo kiekvienos atskiros pagrindinės komponentės tikrines reikšmes, t. y., kiek duomenų sklaidos paaiškina kiekviena komponentė. Šiame grafike matomas vizualinis lūžio taškas, vadinamas „alkūne“, kuris padeda įvertinti, kur baigiasi vertinga informacija.

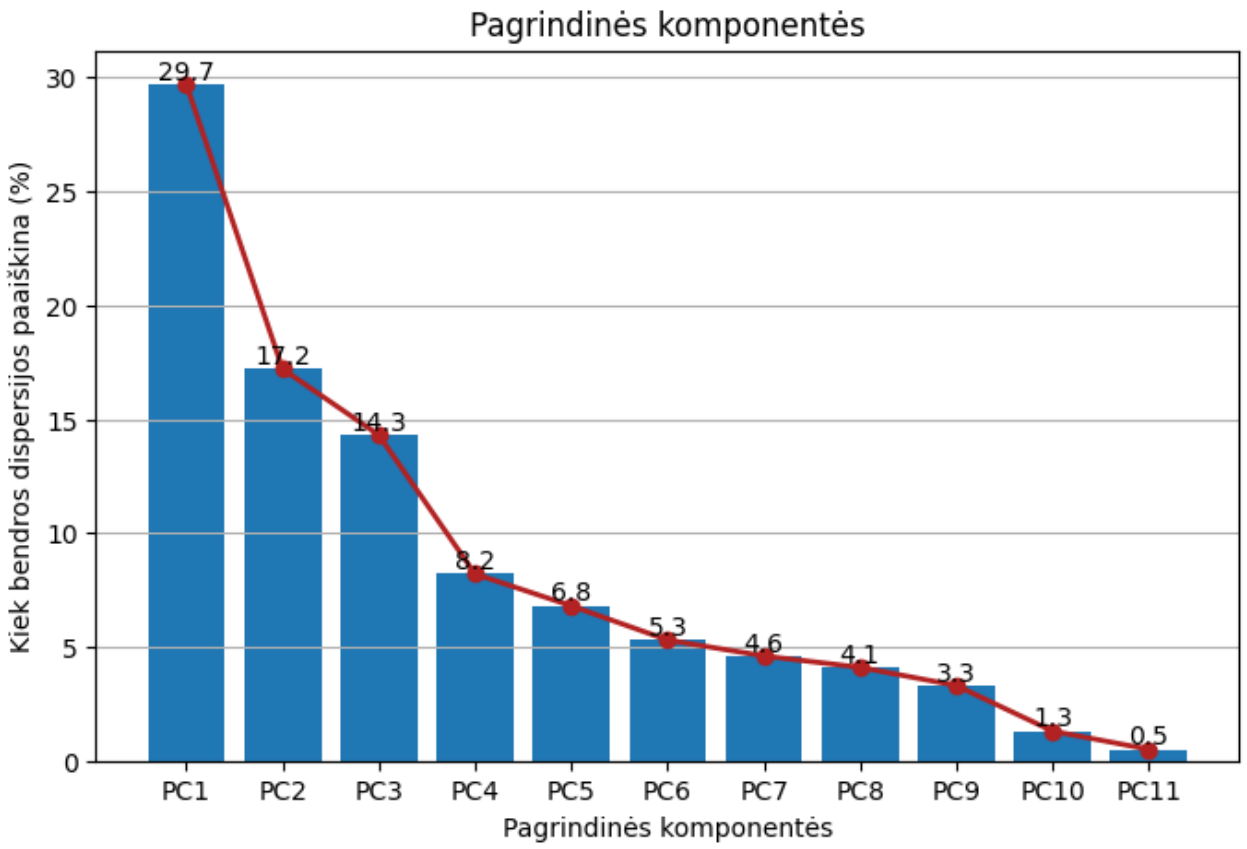

pav. 2: Scree grafikas

Tikrinių vektorių koeficientai

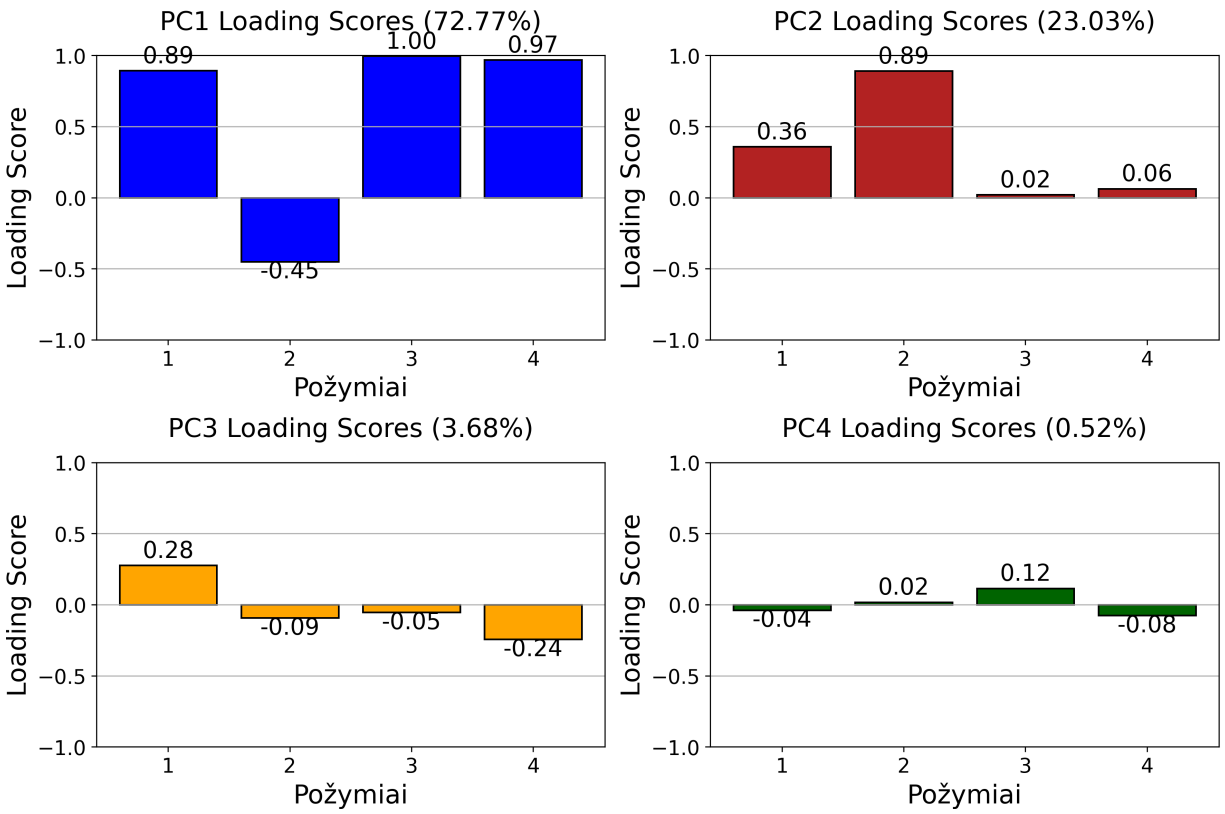

pav. 3: Svorių grafikas

Svorių (angl. *loading scores*) grafikas parodo pradinių požymių įtaką kiekvienai pagrindinei komponentei.

Dvilypė diagrama

Rodyklių kryptis nurodo ar kintamieji teigiamai ar neigiamai koreliuoti, t. y. kryptys tos pačios ar priešingos. Rodyklių ilgis parodo, kiek stipriai požymis prisideda prie komponentės. Kampai nurodo koreliacijos stiprumą: 90°reiškia, kad nėra koreliacijos, 0°- ideali teigiama koreliacija ir 180°- ideali neigiama koreliacija.

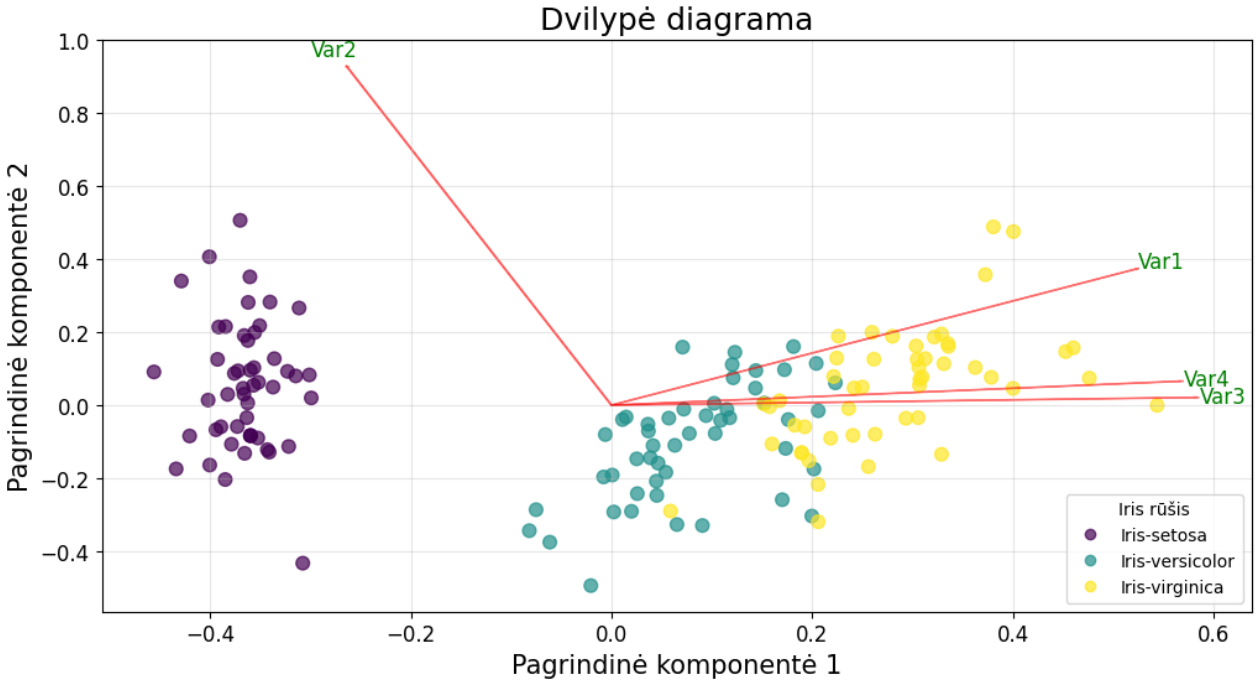

pav. 4: Dvilypė diagrama

1 Įvadas

2 PCA algoritmas

3 PCA modifikacijos

4 Rezultatų interpretacija

5 Privalumai ir trūkumai

6 Išvados

Privalumai

- PCA sumažina kintamųjų skaičių - tai pagreitina kitų algoritmų darbą ir taupo atmintį;
- Palengvina vizualizaciją, duomenų supratimą;
- Šalina multikolinearumą;
- Greitas dėl paprastų skaičiavimų.

Trūkumai

- PCA laikomasi prielaidos, kad ryšiai tarp kintamųjų yra tiesiniai;
- Laikomasi prielaidos, kad didžiausia dispersija yra svarbiausia informacija;
- Esant dideliam požymių skaičiui, bendra duomenų sklaida pasiskirsto per daugybę dimensijų. Tokiu atveju, net pirmoji komponentė gali paaiškinti nedidelę dalį bendros dispersijos. Pavaizdavus duomenis pagal pirmos ir antros komponenčių projekcijas dvimatėje erdvėje gali būti prarandama daug informacijos;
- Jautri išskirtims;
- Nevisos PCA modifikacijos yra realizuotos *Python* aplinkoje.

1 Įvadas

2 PCA algoritmas

3 PCA modifikacijos

4 Rezultatų interpretacija

5 Privalumai ir trūkumai

6 Išvados

Išvados

- Principinių komponenčių analizė (PCA) yra vienas dažniausiai naudojamų metodų duomenų dimensijai mažinti, leidžiantis išlaikyti didžiąją dalį duomenų sklaidos.
- Metodas transformuoja pradinius koreliuotus kintamuosius į naujas tarpusavyje ortogonalias komponentes, kurios aprašo pagrindinę duomenų struktūrą.
- PCA palengvina didelių duomenų rinkinių analizę, pagerina vizualizaciją bei gali pagreitinti kitų algoritmų veikimą.
- Tačiau šis metodas turi ir apribojimų - jis remiasi tiesinių ryšių prielaida, yra jautrus išskirtims ir ne visada lengvai interpretuojamas.
- Dėl šių priežasčių praktikoje dažnai naudojamos įvairios PCA modifikacijos, pritaikytos sudėtingesnėms duomenų struktūroms analizuoti.

Literatūra ir šaltiniai (1/3)

- Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: a review and recent developments. *Phil. Trans. R. Soc. A*, 374(2065), 20150202. DOI: 10.1098/rsta.2015.0202
- Candès, E. J., Li, X., Ma, Y., & Wright, J. (2011). Robust Principal Component Analysis? *Journal of the ACM*, 58(3), Article 11. DOI: 10.1145/1970392.1970395
- Barshan, E., Ghodsi, A., Azimifar, Z., & Jahromi, M. Z. (2011). Supervised principal component analysis: Visualization, classification and regression. *Pattern Recognition*, 44(7), 1357-1371. DOI: 10.1016/j.patcog.2010.12.015
- Jolliffe, I. (1990). Principal component analysis: A beginner's guide - I. *Weather*, 45(10), 375-382. DOI: 10.1002/j.1477-8696.1990.tb05558.x

Literatūra ir šaltiniai (2/3)

- Powell, V., & Lehe, L. (2015). *Principal Component Analysis: Explained Visually*. setosa.io. https://setosa.io/ev/principal-component-analysis/
- Gundersen, G. (2018). *Singular Value Decomposition*. https://gregorygundersen.com/blog/2018/12/10/svd/
- Krasniuk, A. (2024). *The Math Behind the SVD*. Medium. https://medium.com/@krasniuk-ai/the-math-behind-the-singular-value
- GeeksforGeeks (2024). *Principal Component Analysis (PCA)*. https://www.geeksforgeeks.org/principal-component-analysis-pca/
- Wikipedia contributors (2026). *Principal component analysis*. https://en.wikipedia.org/wiki/Principal_component_analysis
- Pedregosa, F., et al. (2024). *sklearn.decomposition.PCA — scikit-learn documentation*. https://scikit-learn.org/stable/modules/generated/sklearn.decomposi PCA.html

Literatūrair šaltiniai (3/3)

- Srinivasan, R. (2021). *5 PCA Visualizations You Must Try on Your Next Data Science Project*. Towards Data Science. https://towardsdatascience.com/5-pca-visualizations-you-must-try-o
- Brunton, S. (2020). *Principal Component Analysis (PCA)*. [Video]. YouTube. https://www.youtube.com/watch?v=fkf4IBRSeEc
- Brunton, S. (2020). *Singular Value Decomposition (SVD): Mathematical Overview*. [Video]. YouTube. https://www.youtube.com/watch?v=nbBvuuNVfco
- Brunton, S. (2021). *Robust Principal Component Analysis (RPCA)*. [Video]. YouTube. https://www.youtube.com/watch?v=yDpz0PqULXQ
- Kamper, H. (2020). *PCA 6 - Relationship to SVD*. [Video]. YouTube. https://www.youtube.com/watch?v=DQ_BkPHIl-g